

Matriz de Optimización de Costos — Modelos de IA

Entregable independiente · Proyecto: Automatización de calificación de leads con IA (n8n) · Compara GPT-4o-mini, Claude y Batch API por tipo de tarea, con max_tokens estimado y ahorro proyectado.

1. Contexto

El flujo actual usa un único modelo (gpt-4.1-mini) para toda la generación de texto: el briefing de ventas que el AI Agent produce a partir del comentario del formulario. Esta matriz evalúa esa elección para la tarea real del proyecto y la compara con alternativas —GPT-4o-mini, Claude (Sonnet) y procesamiento por lotes (Batch API)— para justificar cuándo conviene escalar de modelo o cambiar de modo de procesamiento, incluyendo una estimación de max_tokens por tarea y el ahorro esperado frente a la línea base.

2. Comparativa por tarea

Tarea	Modelo usado / recomendado	max_tokens estimado (in / out)	Justificación	Costo relativo aprox.*	Ahorro estimado vs. línea base
Generación de briefing de ventas por lead (tarea actual: 1 lead a la vez, JSON estructurado corto)	GPT-4o-mini	~900 in / ~450 out	Razonamiento simple sobre poco texto (system prompt + 1–2 frases de comentario + 5 campos). No requiere ventana de contexto grande ni razonamiento profundo: un modelo mini resuelve la clasificación bajo/media/alto y el resumen sin pérdida de calidad perceptible frente a un modelo de mayor tamaño. Sustituye a gpt-4.1-mini con precio por token más bajo y misma familia de calidad.	1x (línea base)	Base de comparación
Análisis de documentos extensos del cliente (estados de cuenta, formularios KYC largos, PDFs de 10+ páginas)	Claude (Sonnet)	~15,000–40,000 in / ~1,500 out	Lectura densa y de mayor longitud se beneficia de modelos con mejor comprensión de contexto largo y menor tasa de alucinación en extracción factual, relevante si el fondo escala a validar documentación financiera y no solo comentarios cortos de formulario.	~3–5x por token	Evita reprocesos por errores de extracción; se paga el sobrecosto solo en el subconjunto de casos que lo requiere

Tarea	Modelo usado / recomendado	max_tokens estimado (in / out)	Justificación	Costo relativo aprox.*	Ahorro estimado vs. línea base
Reprocesamiento masivo nocturno (re-scorear potencial de negocio de todos los leads del mes o generar briefings para una base histórica)	Batch API (OpenAI Batches / Anthropic Message Batches)	~900 in / ~450 out por lead (mismo payload que la tarea 1, procesado en lote)	Procesos que no requieren respuesta en tiempo real (no hay un asesor esperando el resultado en segundos) son candidatos ideales para la API de lotes, que no compite con el flujo en vivo del formulario.	~0.5x del costo estándar del mismo modelo	~50% adicional sobre ese lote específico frente a procesar el histórico por la ruta en vivo
Conversación en vivo con el cliente (fuera de alcance actual; expansión posible: chatbot de primer contacto)	GPT-4o-mini o Claude Haiku	~300 in / ~150 out por turno	Interacción conversacional simple y de bajo riesgo (preguntas frecuentes, precalificación) no necesita un modelo de frontera; se prioriza latencia y costo por sobre profundidad de razonamiento.	1x	N/A (caso de expansión, no reemplaza tarea actual)

*Costo relativo estimado por token/solicitud frente a la línea base (GPT-4o-mini para la tarea actual del briefing de ventas), no cifras absolutas de mercado. Los valores de max_tokens son estimaciones de diseño basadas en el tamaño real del prompt del sistema, el payload del formulario y el esquema del Structured Output Parser; sirven para presupuestar y priorizar decisiones, no como cotización exacta del proveedor.

3. Ahorro estimado

- Usar GPT-4o-mini en vez de un modelo de frontera (p. ej. GPT-4.1 completo o GPT-4o full) para el briefing de ventas representa una reducción de costo por token de aproximadamente 80–90% frente a los modelos “full-size” equivalentes de la misma familia, sin degradar la tarea porque el input es corto y estructurado (menos de 1,000 tokens de entrada).
- Si el volumen de leads creciera a un punto donde se necesite reprocesar históricos (por ejemplo, re-evaluar potencial de negocio con un prompt mejorado sobre miles de filas ya existentes), migrar ese caso puntual a Batch API evita duplicar el costo de la ruta en vivo y puede ahorrar hasta ~50% adicional sobre ese lote específico, sin impacto en la latencia percibida por el asesor (proceso nocturno, no bloqueante).
- Reservar un modelo más costoso (Claude) solo para los casos de lectura densa (documentos KYC, estados de cuenta) evita pagar ese sobre costo en el 100% del volumen: se paga la diferencia únicamente en el subconjunto de tareas que realmente lo requieren, manteniendo el costo promedio por lead cercano a la línea base.
- Estimación combinada: si del volumen mensual de leads solo un 10–15% requiriera eventualmente análisis documental con Claude, el costo total mensual de IA del flujo se mantendría cercano a 1.3x–1.6x de la línea base, muy por debajo de usar un modelo de frontera para el 100% del volumen (que rondaría 5x–8x).

4. Criterio de selección resumido

Señal	Modelo/modo recomendado
Input corto (<1,000 tokens), tarea estructurada, respuesta en tiempo real	GPT-4o-mini
Input largo (documentos de varias páginas), riesgo de alucinación con impacto financiero/legal	Claude (Sonnet)
Volumen alto, sin usuario esperando respuesta inmediata (reprocesos, históricos)	Batch API (con el modelo que corresponda según el punto anterior)
Conversación de baja complejidad, muchas interacciones cortas	GPT-4o-mini o Claude Haiku